

Práctica de Visualización de Datos: Licitaciones Públicas y Mercados Financieros

Asignatura: Visualización de Datos

Estudiante: Julián Cámara (Jcamara48)

Dataset: Licitaciones de la Junta de Andalucía (2023) y Correlación Bursátil

1. Selección y Justificación del Conjunto de Datos

La selección de mi conjunto de datos proviene de la **plataforma abierta y oficial** datos.gob.es (en la cual los ciudadanos pueden acceder a los conjuntos de datos generados por las administraciones públicas) respondiendo y cumpliendo a un **interés profesional y general en el ámbito de la transparencia administrativa y la economía financiera**.

Tras realizar una búsqueda por **licitaciones o adjudicaciones** en el buscador de la página indicada arriba, de las varias opciones disponibles me decanté por el de la **Junta de Andalucía** y, para cumplir con el requisito de actualidad, elegí el **año 2023**.

Mi objetivo es explorar **cómo el gasto público masivo de una administración regional como la Junta de Andalucía impacta o se refleja en la valoración de mercado de las empresas cotizadas en bolsa**. De esta manera cumplo con los temas que puedan ser adecuados para la práctica, así como con los **aspectos de relevancia para la sociedad, de complejidad** por la obtención y combinación de los datos y las características de estos como veremos más adelante, **así como de originalidad** por no repetir un tema ya tratado en los ejemplos dados y por no estar basado en ningún trabajo anterior.

Si bien, teniendo **datos cuantitativos, temporales y ordinales** puedo responder a varios tipos de preguntas diferentes, siendo inversor en bolsa siempre me he preguntado cómo la información privilegiada de los contratos o “procurement” que obtienen las empresas y los trabajadores de dentro de la empresa o un círculo cerrado de personas conocedoras de esto, influye en las subidas y bajadas de precio bursátil, es decir, mi objetivo es romper con las visualizaciones o disyuntivas de “quién gana más” para entrar en una narrativa de **"impacto corporativo"**, y analizar cómo las grandes adjudicaciones de contratos públicos actúan como catalizadores de confianza para los inversores en bolsa.

2. Relevancia y Contexto

¿Son **datos actuales** o actualizados recientemente?

Los datos si los considero actuales al estar en un horizonte menor a 36 meses con respecto a la fecha presente y si bien no son actualizados recientemente puesto que corresponden al ejercicio fiscal **2023**, cumplen con la normativa y ofrecen una visión contemporánea de la inversión pública post-pandemia y de plena ejecución de ayudas y fondos europeos.

¿Tratan un **tema importante para algún colectivo** concreto? ¿Son **de relevancia para un sector profesional concreto**?

El dataset tiene una **connotación social y profesional** ya que es de vital importancia para el sector de la consultoría, la construcción y la tecnología. Además, permite una diferenciación sobre la concentración de contratos en grandes corporaciones frente al tejido de PYMES locales.

¿Se ha tenido **en cuenta la perspectiva de género**?, ¿Tienen una **connotación social**? **De alguna manera, si tienen perspectiva social** ya que **la naturaleza de datos son socioeconómicos** (capital, entidades legales, tiempos de administración, gasto público etc) y el análisis de éstos me permite **observar si existe una diversidad sectorial** en el liderazgo de las empresas receptoras de fondos públicos, así como una **información de donde es destinado nuestro dinero como contribuyentes**, pero en este caso en particular, y por el objetivo sacado de ellos, **no he tenido en cuenta una perspectiva de género**.

3. Complejidad del Dataset

Según la descripción oficial, el dataset muestra Información sobre las licitaciones publicadas en los distintos Perfiles de Contratante de la Administración de la Junta de Andalucía para el año 2023 (se excluyen expedientes de contratos menores).

El **conjunto de datos original** reúne:

- Datos generales del expediente
- Información sobre el lugar de ejecución (código de la Subentidad Nacional, Subentidad Territorial y población)
- Información sobre los lotes
- Información sobre el tipo de procedimiento
- Datos sobre ubicación orgánica, nombre e ID de la entidad adjudicadora
- Información sobre plazo de presentación de oferta
- Información sobre el plazo de presentación de solicitudes
- Información sobre el resultado del procedimiento (resultado, lote, fecha del acuerdo, ofertas recibidas)
- Información sobre adjudicatario
- Información sobre importes de adjudicación

- Información sobre publicaciones oficiales La publicación de los datos se realiza en cumplimiento de lo establecido en el artículo 63 de la Ley 9/2017, de 8 de noviembre, de Contratos del Sector Público, por la que se transponen al ordenamiento jurídico español las Directivas del Parlamento Europeo y del Consejo 2014/23/UE y 2014/24/UE, de 26 de febrero de 2014 y para facilitar el acceso a la ciudadanía, a las empresas y personas licitadoras.

Tras analizar la **estructura original del repositorio** de datos.gob.es, que **incluye metadatos** de gestión administrativa (plazos de licitación, códigos territoriales y detalles de lotes), **he realizado una selección estratégica de variables, priorizando aquellas con valor económico y financiero (Importe, Adjudicatario y Fecha) para reducir la dimensionalidad del dataset y centrar el análisis en el impacto presupuestario y su correlación con los mercados de capitales**, eliminando el ruido administrativo que no aporta valor.

Considero que mi proyecto destaca por su alta complejidad técnica en la fase de preparación, y analizando cómo se evalúa esta parte, cumplo con la excelencia, ya que alcanzo el mínimo de número de registros, así como la diferente tipología de las variables y de datos estructurados y semiestructurados viniendo de un archivo de Extensible Markup Language.

A continuación muestro las principales características:

Con respecto al **volumen del dataset**, se procesaron inicialmente **12.012 archivos XML** individuales, (Ver el treeXML más abajo con la estructura de cada una de ellos). Tras un proceso de extracción y limpieza, he consolidado un dataset con **4.631 registros válidos**.

La **tipología de variables** es diversa ya que combina datos **cuantitativos** (Importes de licitación que superan los 6.800 millones de euros en total) con datos **categoricos** (NIF, nombres de empresas, títulos de proyectos).

Por último **el desafío técnico y el rigor en el proceso de la obtención de los datos** me requirió de programación a través de Google Colab de un script avanzado en **Python** para realizar un **recorrido recursivo de directorios, gestión de namespaces XML complejos y normalización de tipos de datos (conversión de String a Float)**, técnicas todas vistas en asignaturas anteriores.

El treeXML de cada uno de los archivos sigue el siguiente esquema, el cual explico más adelante: (esto se vio en la asignatura de programación con python así como la librería ElementTree para leer y parsear)

```
<entry xmlns="http://www.w3.org/2005/Atom"
xmlns:cac="urn:dgpe:names:draft:codice:schema:xsd:CommonAggregateComponents-2"
"
xmlns:cac-place-ext="urn:dgpe:names:draft:codice-place-ext:schema:xsd:CommonA
ggregateComponents-2"
xmlns:cbc="urn:dgpe:names:draft:codice:schema:xsd:CommonBasicComponents-2"
xmlns:cbc-place-ext="urn:dgpe:names:draft:codice-place-ext:schema:xsd:CommonB
```

asicComponents-2"

xmlns:ns1="urn:oasis:names:specification:ubl:schema:xsd:CommonExtensionComponents-2">

<id>https://contrataciondelestado.es/sindicacion/PlataformasAgregadasSinMenores/12515157</id>

<link
href="https://www.juntadeandalucia.es/haciendayadministracionpublica/apl/pdc_sirec/perfiles-licitaciones/detalle-licitacion.jsf?idExpediente=10996"/>

<summary type="text">Id licitación: 2021-698307; Órgano de contratación: Consejería de Justicia, Administración Local y Función Pública. Secretaría General Técnica; Importe: 30.786,60 €;</summary>

<title>lectores tarjetas next generation</title>

<updated>2023-04-10T10:11:29.182+02:00</updated>

<cac-place-ext:ContractFolderStatus>

<cbc:ContractFolderID>2021-698307</cbc:ContractFolderID>

<cbc-place-ext:ContractFolderStatusCode languageID="es"
listURI="https://contrataciondelestado.es/codice/cl/2.04/SyndicationContractFolderStatusCode-2.04.gc">RES</cbc-place-ext:ContractFolderStatusCode>

<cac-place-ext:LocatedContractingParty>

<cac:Party>

<cac:PartyName>

<cbc:Name>Consejería de Justicia, Administración Local y Función Pública. Secretaría General Técnica</cbc:Name>

</cac:PartyName>

</cac:Party>

<cac-place-ext:ParentLocatedParty>

<cac:PartyName>

<cbc:Name>Junta de Andalucía</cbc:Name>

</cac:PartyName>

<cac-place-ext:ParentLocatedParty/>

</cac-place-ext:ParentLocatedParty>

```

</cac:place-ext:LocatedContractingParty>

<cac:ProcurementProject>

  <cbc:Name>lectores tarjetas next generation</cbc:Name>

  <cbc:TypeCode
listURI="http://contrataciondelestado.es/codice/cl/2.08/ContractCode-2.0
8.gc">1</cbc:TypeCode>

  <cac:BudgetAmount>

    <cbc:EstimatedOverallContractAmount
currencyID="EUR">30786.6</cbc:EstimatedOverallContractAmount>

    <cbc:TaxExclusiveAmount
currencyID="EUR">30786.6</cbc:TaxExclusiveAmount>

  </cac:BudgetAmount>

  <cac:RequiredCommodityClassification>

    <cbc:ItemClassificationCode
listURI="http://contrataciondelestado.es/codice/cl/2.04/CPV2008-2.04.g
c">30162000</cbc:ItemClassificationCode>

  </cac:RequiredCommodityClassification>

  <cac:RealizedLocation>

    <cbc:CountrySubentityCode
listURI="http://contrataciondelestado.es/codice/cl/2.08/NUTS-2021.gc">
ES61</cbc:CountrySubentityCode>

  </cac:RealizedLocation>

  <cac:PlannedPeriod>

    <cbc:DurationMeasure unitCode="DAY">60</cbc:DurationMeasure>

  </cac:PlannedPeriod>

</cac:ProcurementProject>

<cac:TenderResult>

  <cbc:ResultCode
listURI="http://contrataciondelestado.es/codice/cl/2.09/TenderResultCode
-2.09.gc">8</cbc:ResultCode>

  <cbc:ReceivedTenderQuantity>2</cbc:ReceivedTenderQuantity>

```

```

<cac:WinningParty>

  <cac:PartyIdentification>

    <cbc:ID schemeName="NIF">B83029439</cbc:ID>

  </cac:PartyIdentification>

  <cac:PartyName>

    <cbc:Name>BECHTLE DIRECT SL</cbc:Name>

  </cac:PartyName>

</cac:WinningParty>

<cac:AwardedTenderedProject>

  <cac:LegalMonetaryTotal>

    <cbc:TaxExclusiveAmount
      currencyID="EUR">30786.6</cbc:TaxExclusiveAmount>

  </cac:LegalMonetaryTotal>

</cac:AwardedTenderedProject>

</cac:TenderResult>

<cac:TenderingProcess>

  <cbc:ProcedureCode
    listURI="https://contrataciondelestado.es/codice/cl/2.07/SyndicationTenderingProcessCode-2.07.gc">7</cbc:ProcedureCode>

</cac:TenderingProcess>

<cac-place-ext:ValidNoticeInfo>

  <cbc-place-ext:NoticeTypeCode
    listURI="http://contrataciondelestado.es/codice/cl/2.08/TenderingNoticeTypeCode-2.08.gc">DOC_CAN_ADJ</cbc-place-ext:NoticeTypeCode>

  <cac-place-ext:AdditionalPublicationStatus>

    <cbc-place-ext:PublicationMediaName>Perfil del
      contratante</cbc-place-ext:PublicationMediaName>

    <cac-place-ext:AdditionalPublicationDocumentReference>

      <cbc:IssueDate>2023-04-10</cbc:IssueDate>

```

```

        </cac-place-ext:AdditionalPublicationDocumentReference>

        </cac-place-ext:AdditionalPublicationStatus>

        </cac-place-ext:ValidNoticeInfo>

        </cac-place-ext:ContractFolderStatus>

    </entry>

```

¿Que es este XML, qué contiene, cómo está organizado y qué partes son relevantes para extraer datos?

Para hablar del xml debo ponerlo primero en contexto hablando de la **Plataforma de Contratación del Sector Público (PLACSP)**, portal público y gratuito, que es un sistema digital que concentra la información de contratación pública en España, funcionando como un punto de encuentro virtual entre empresas y autónomos, órganos públicos y consultoras y asesorías. Su objetivo principal es facilitar la transparencia, eficiencia y publicidad en los procesos de licitación.

Una vez se descomprime el archivo de 2023 cada XML que aparece corresponde a una licitación diferente, codificada según **el estándar CODICE (basado en UBL 2.x)**.

La estructura general del XML es la siguiente:

El nodo raíz es <entry> cada uno es un expediente, y **dentro hay varios metadatos** o bloques clave:

<id> URL unica del expediente en el feed

<link> enlace al perfil del contratante

<summary> resumen textual

<title> titulo de la licitación

<updated> fecha de actualización del expediente.

Despues hay varios bloques o núcleos principales de los expedientes dentro de **ContractFolderStatus** esta la **identificación o ID de éste**

Dentro de **LocatedContractingParty** esta el organo de contratación su **<Name>**

Si bien la info objeto de análisis está dentro de **<ProcurementProject>**

<Name> es el objeto de contrato

<TypeCode> tipo de contrato

<EstimatedOverallContractAmount> el importe estimado

<DurationMeasure> La duración prevista

Por último la información del resultado y proceso de licitación se ve después del namespace <TenderResult> donde está el nif, nombre e importe del adjudicatario dentro de <WinningParty>

4. Originalidad y Enriquecimiento

A diferencia de otros proyectos más estándar circulando por Internet o con temática más trillada, bajo mi punto de vista, este trabajo presenta una excelente **originalidad técnica y temática** como indican los criterios de evaluación por las siguientes razones:

1- Enriquecimiento: No me voy a limitar a una sola fuente. Voy a cruzar los datos de la Plataforma de Contratación con indicadores de mercado (IBEX 35 y SP500).

En yahoo finance o Morningstar puedo buscar el tickr de las empresas que cotizan y descargar el histórico de precios de 2023.

Siguiendo el ejemplo del video de Youtube [Análisis de Acción en Python con Google Colab y Yahoo Finance](#) y simplificando muchísimo (Ver cuaderno Colab adjunto en la entrega de la práctica)

Para enriquecer el dataset original, he realizado una conexión a una fuente externa de datos financieros utilizando la **librería yfinance** en Google Colab.

Esta librería permite acceder de forma sencilla a los datos históricos de mercado proporcionados por Yahoo Finance, sin necesidad de trabajar directamente con una API compleja o credenciales de autenticación.

El resultado de esta consulta es un dataset estructurado en formato tabular que incluye variables como la **fecha de cotización, los precios de apertura, máximo, mínimo y cierre, así como el volumen de negociación.**

A continuación pongo el resultado de **la empresa Endesa que elegí por ser unas del top10 de gasto invertido** que muestra mi gráfico realizado en el punto 5:

	Date	Open	High	Low	Close	\
0	2023-01-02 00:00:00+01:00	14.530436	14.718717	14.444481	14.669600	
1	2023-01-03 00:00:00+01:00	14.653227	14.894719	14.546808	14.739182	
2	2023-01-04 00:00:00+01:00	14.816954	15.349055	14.816954	15.295844	
3	2023-01-05 00:00:00+01:00	15.218075	15.349054	15.062538	15.123935	
4	2023-01-06 00:00:00+01:00	15.156676	15.398168	15.062535	15.394075	

	Volume	Dividends	Stock	Splits
0	528063	0.0		0.0
1	1185399	0.0		0.0
2	2089191	0.0		0.0
3	1641596	0.0		0.0
4	821399	0.0		0.0

2- Generación de métricas: Voy a crear indicadores de **Concentración de Adjudicación por sectores** y quiero **segmentar** el tejido empresarial entre **grandes corporaciones** cotizadas y entidades más locales (**pymes**). En futuras ampliaciones de proyecto **podría considerar un mapa por regiones** en el que el objetivo sea **ver la concentración territorial** del gasto público.

3- Transformación: He aplicado **técnicas de Data Wrangling** para corregir colisiones de delimitadores y normalizar nombres de empresas mediante expresiones regulares que explico en mayor detalle a continuación tanto en los pasos acometidos como en los problemas encontrados:

Notas sobre la preparación de datos y creación de un gráfico.

Para asegurar la calidad de la visualización, he realizado **una normalización de la configuración regional (puntos por comas)** puesto que el uso de comas dentro de los nombres de empresas me provocaba que los datos se desplazarán a columnas incorrectas.

Otro problema encontrado fue que **Excel interpreta los importes como texto**, lo que hacía que la suma en la tabla dinámica fuera 0. La solución está en **hacer una transformación forzosa del tipo de dato** como valor para ver que los 6812 millones de € totales de gasto que hubo en la junta de Andalucía en el año 2023 fueran computables.

Una vez realizado el pivot table se hace una **poda de registros incompletos**, pasando de un dataset de **4632 filas u observaciones** que lo que indican son los contratos **individuales** a un resumen con entidades únicas de **1440 filas** que me permite ver cómo **varias empresas adjudicatarias son repetitivas**.

Todas estas transformaciones anteriores me garantizan que más adelante, **en la última fase de ETL (Extract Transform and Load)** me garantice que **la carga de datos en herramientas como Tableau o PowerBI** para la creación de gráficos y visualizaciones **sea eficiente y libre de ruido**.

5. Cuestiones y Objetivos de la Visualización

El objetivo principal de la visualización no es únicamente describir los datos, sino construir una narrativa que permita entender cómo el gasto público puede influir en el comportamiento de ciertas empresas en los mercados financieros.

A partir del dataset generado, la visualización final buscará dar respuesta a las siguientes preguntas:

1. ¿Cómo se distribuye el gasto público a lo largo del tiempo?

Se busca **identificar si existen patrones temporales en la adjudicación de contratos** (por meses o trimestres), detectando posibles picos de inversión pública. Esto me permitirá entender **si el gasto es uniforme o si responde a ciclos administrativos** o presupuestarios.


En la futura práctica **para dar respuesta a la pregunta planteada de la evolución temporal del gasto podría hacer un gráfico de líneas** y centrarme en los patrones temporales con el objetivo de ver los picos en las adjudicaciones mensuales.

2. ¿Qué empresas concentran mayor volumen de adjudicación?

Se analizará **qué empresas reciben mayor cantidad de contratos y volumen económico total**. El objetivo aquí no es solo hacer un ranking, sino detectar y ver qué **concentración de mercado** ocupan estas empresas

Como primera aproximación exploratoria, genero un gráfico de barras horizontales o Pivot Chart, a partir de la tabla dinámica, en **el que veo el top 10** los de las corporaciones y los volúmenes de inversión en ellas.

El resultado es:



Como comentario al gráfico (si bien aparecen nombres como Ver resolución adjunta o entidades relacionadas en el anexo, que son inconsistencias y dan la necesidad de aplicar procesos de limpieza adicionales en fases posteriores), **observo una fuerte concentración del gasto en un número reducido de entidades.**

3. ¿Existe desigualdad entre grandes empresas y PYMES?

Intentaré **comparar el volumen de adjudicación** entre las grandes empresas (que serán las únicas potencialmente cotizadas) con las asociaciones o pequeñas y medianas empresas que me indicará si **existe una brecha de inversión en el dinero destinado de todos los contribuyentes.**

Como propuesta de visualización podría hacer un gráfico que extienda el mostrado en el apartado anterior de barras apiladas o treemap para ver la desigualdad.

4. ¿Se pueden detectar eventos relevantes para empresas cotizadas?

Considero a esta es la parte más diferencial del proyecto, puesto que quiero analizar la correlación bursátil de empresas que cotizan en bolsas extranjeras (principalmente USA en el SP500 como Abbott, Berkshire Hathaway etc y otras del mercado nacional Ibex 35 como Endesa o Telefónica)

Por correlación bursátil me refiero a **un análisis temporal y detección de patrones o tendencias alcistas coincidentes con los periodos de adjudicación que me informen de posibles eventos de interés como inversor.**

Esta va a ser el gráfico más complejo de mi proyecto, puesto que debe ser cruzado de líneas o puntos con los eventos

5. ¿Existen sectores más beneficiados por el gasto público?

A partir del título de las licitaciones (o también es posible a través del contraste con informes empresariales o bursátiles donde viene informado el sector al que pertenece la empresa) y su categorización posterior, intentaré **identificar los sectores más predominantes (tecnología, construcción, servicios, etc.)** consiguiendo también ver una evolución del gasto por tipo de actividad.

En cuanto al gráfico, como debo comparar magnitudes y ordenar de mayor a menor o viceversa de nuevo podría hacer un bar chart en el que en el eje x contenga los sectores y el y los importes totales adjudicados

A continuación incluyo **el diccionario detallado que diferencia claramente entre hechos y dimensiones del conjunto de datos obtenido:**

VARIABLE	TIPO DE DATO	SIGNIFICADO	FUNCION
Título	Categórico	Descripción del objeto de contrato	Dimensión
Importe	Cuantitativo	Valor Económico en €	Hecho (Métrica)
Empresa	Categórico	Nombre legal de la entidad	Dimensión
NIF	Categórico	Identificador fiscal de la empresa	Dimensión
Fecha_Publicación	Temporal	Fecha de publicación del expediente	Dimensión
Fecha_Adjudicación	Temporal	Fecha oficial del contrato	Dimensión
Tickr o abreviatura	Categorico	Símbolo bursátil	Dimensión
Sector	Categórico	Tipo de actividad	Dimensión
Volumen de empresa	Cuantitativo	Total adjudicado por empresa	Hecho

